


1、原版代价函数

在线性回归拟合中，我们利用代价函数求偏导的思想，对 θ 参数进行逐步优化，使得最后的代价差为局部最优值。同样，我们来看，这样的思想能否也利用在 logistic 模型优化中呢？



Logistic 模型， $h_{\theta}(x) = \frac{1}{1+e^{-\theta^T x}}$ ，若用 $J(\theta)$ 进行优化，得到的图形是这样的，它是一个非凸函数，因此我们无法通过原来的代价函数进行梯度下降得到想要的 θ 值。



2、新版代价函数

针对新的模型，应用新的参数求解过程。直接看定义：

$$Cost(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$



在左图中，当样本点属于 1 结果时，此时计算它的代价函数为 $-\log(h_{\theta}(x))$ ，若 $h_{\theta}(x)$ 预测值为 1 时，代价为 0，反之趋于无穷，这就限制住了对样本值为 1 的点预测它趋于 0 的可能性；右图同理，若 $h_{\theta}(x)$ 预测值为 0 时，代价为 0，反之趋于无穷，这就限制住了对样本值为 0 的点预测它趋于 1 的可能性。

到目前为止，我们学会了用 logistic 模型拟合分类训练集，对训练集拟合的好坏，给出了新的代价函数方程。接下来，通过梯度下降算法来给出一个较好的 θ 。

3、梯度下降算法——优化 θ

之前用方程组的形式表示出当 y 为 0、1 时的代价函数，现在用一个式子来表示：

$$Cost(h_{\theta}(x), y) = -y \log(h_{\theta}(x)) + (y - 1) \log(1 - h_{\theta}(x)) \quad , \quad y = 0/1$$

这是对单个样本进行代价值计算，现在扩展到所有训练集中，得出总的代价函数为：

$J(\theta) = -\frac{1}{m} [\sum_{i=1}^m y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))]$ ，值得庆幸的是，这个代价函数是一个凸函数，因此可以用梯度下降算法进行 θ 值的迭代更新：

$$\left\{ \begin{array}{l} \theta_j = \theta_j - \alpha \frac{1}{m} \frac{\partial}{\partial \theta_j} J(\theta) \\ \theta_j = \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} \end{array} \right.$$

可以看到，这一个对 θ 值的更新，与之前讲的线性回归梯度下降算法所用公式是一样的，但其实本质是不同的，因为对预测模型的定义完全不同。同样，向量化运算和特征值缩放也适用于 logistic 模型。

参数值更新： $\theta = \theta - \alpha \frac{1}{m} X' * (y_{\text{pred}} - y)$,

代价函数计算： $J = -\frac{1}{m} \text{sum}(y.* \log(y_{\text{pred}}) + (1 - y).* \log(1 - y_{\text{pred}}))$